

Previsão de Vida Útil Remanescente de Motores Aeronauticos

1st Davi Grumiche Seemann
dept. Engenharia Elétrica
Universidade Federal de Santa Catarina
Florianópolis, SC
daviseemann@gmail.com

I. INTRODUÇÃO

A manutenção preditiva tem se tornado um pilar estratégico em indústrias intensivas em ativos, pois permite substituir o paradigma “*correção após falha*” por intervenções programadas de forma inteligente, baseadas no estado real do equipamento. Para habilitar esse cenário, é fundamental estimar com precisão a Vida Útil Remanescente (*Remaining Useful Life – RUL*) de componentes sujeitos a desgaste progressivo, como turbinas aeronáuticas, locomotivas e compressores.

A. Motivação

Meu interesse de pesquisa está em *séries temporais multivariadas*. Ao revisar a literatura, chamou-me atenção o trabalho de Laredo *et al.* [1], cuja Arquitetura 1, um MLP alimentado por janelas planificadas atingiu desempenho competitivo em problemas de RUL, desafiando a noção de que apenas redes recorrentes dominam esse domínio. Este projeto, portanto, tem como meta principal *replicar e analisar* essa arquitetura usando dados públicos, avaliando o quanto ajustes de hiperparâmetros influenciam o resultado.

B. Escolha do benchmark

O *Turbofan Engine Degradation Simulation* (C-MAPSS), disponibilizado pela NASA [2], é um benchmark de RUL muito conhecido. O conjunto oferece leituras de 24 sinais (21 sensores + 3 configurações) para motores simulados até a falha, permitindo testar modelos de prognóstico em ambiente controlado e reproduzível.

C. Objetivos deste trabalho

- 1) Construir um *pipeline* completo, de pré-processamento a avaliação, para o subconjunto FD001 do C-MAPSS.
- 2) Replicar a Arquitetura 1 de Laredo *et al.* [1] em âmbito acadêmico, avaliando a influência de hiperparâmetros e das decisões de *clipping* de RUL.

A seção seguinte revisa os trabalhos mais relevantes sobre prognóstico de turbinas e posiciona esta pesquisa no estado da arte.

D. Trabalhos Relacionados

O conjunto C-MAPSS, detalhado em [2], tornou-se o padrão de facto para validar técnicas de prognóstico de *Remaining Useful Life* (RUL) em turbinas.

TABLE I
RESULTADOS ATINGIDOS NO ARTIGO DE LAREDO *et al.* [1]

Data subset	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
FD001	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11

1) *Arquiteturas recorrentes.*: Uma linha de pesquisa dominante explora redes LSTM para capturar dependências temporais de longo prazo. Malhotra *et al.* [3] introduziram um *encoder-decoder* LSTM originalmente voltado para detecção de anomalias multissensoriais, mas rapidamente adaptado à estimativa de RUL no C-MAPSS, estabelecendo um patamar de desempenho que motivou diversas variações subsequentes.

2) *Arquiteturas densas.*: Contrariando a percepção de que somente modelos recorrentes ou Transformers seriam adequados, Laredo *et al.* [1] propuseram uma estrutura de MLP mais simples na qual a Arquitetura 1 consiste em um MLP alimentado por janelas planificadas dos sinais. Apesar da simplicidade, os autores reportaram resultados próximos aos melhores LSTM, abrindo espaço para investigações focadas em ajuste de hiperparâmetros e regularização, exatamente o escopo deste trabalho.

Em síntese, os estudos acima oferecem duas vertentes contrastantes: (a) redes recorrentes profundas com forte capacidade sequencial e (b) MLPs compactas, cuja eficácia depende de pré-processamento e tuning cuidadoso. Este projeto posiciona-se na segunda vertente, replicando e aprofundando a análise da Arquitetura 1 de Laredo *et al.* [1].

Os resultados a serem buscados especialmente no baseline são os seguintes.

II. METODOLOGIA

A. Conjunto de Dados

Utiliza-se o subconjunto FD001 do C-MAPSS [2], composto por leituras de 100 motores para treino (até a falha) e 100 para teste (trajetórias truncadas). Cada amostra contém 24 variáveis: 21 sensores físicos $S_1 - S_{21}$ e 3 configurações operacionais op_{1-3} .

B. Pré-processamento

1) *Escolha dos sensores relevantes.*: A partir dos estudos de [4] e do artigo de referência [1] foram verificados que alguns sinais de sensores tinham pouco ou nenhuma correlação com a variável alvo do *dataset*. Assim este trabalho assume essa premissa como base para a escolha dos sensores as serem utilizados na parte de treino e teste do modelo. Os índices dos sensores a serem utilizados: 2, 3, 4, 7, 8, 9, 11, 12, 13, 14, 15, 17, 20, 21.

O comportamento dos sensores escolhidos podem ser observados na figura 1

2) *Divisão entre treino e validação.*: Dos 100 motores disponíveis para treino, foi realizada a divisão por *id* de 20% dos motores para validação, ou seja, 20 motores.

3) *Normalização por motor.*: Para eliminar o viés introduzido por diferentes regimes operacionais, cada sinal foi escalonado por motor usando a normalização *min-max* no intervalo $[-1, 1]$. A Eq. (1) mostra a transformação aplicada a cada amostra $x_{i,t}$ do sensor i no ciclo t :

$$\hat{x}_{i,t} = 2 \frac{x_{i,t} - x_i^{\min}}{x_i^{\max} - x_i^{\min}} - 1, \quad (1)$$

em que $x_i^{\min} = \min_t x_{i,t}$ e $x_i^{\max} = \max_t x_{i,t}$ são, respectivamente, o mínimo e o máximo observados para o sensor i ao longo de todo o histórico daquele motor. Dessa forma, obtém-se $\hat{x}_{i,t} \in [-1, 1]$, preservando a variabilidade relativa interna de cada sensor enquanto se remove a influência das diferenças absolutas entre motores.

4) *Segmentação por janela deslizante.*: A etapa de pré-processamento adotou a estratégia de *janela deslizante* (*sliding window*) para converter as sequências de dados, de comprimento variável, em vetores de dimensão fixa adequados aos modelos de regressão. Para cada ciclo operacional t , foi construído um subconjunto $X_t \in \mathbb{R}^{w \times 24}$ contendo os w ciclos imediatamente anteriores (inclusive t); em seguida, X_t foi *planificado* linha a linha, originando o vetor de entrada $\mathbf{x}_t \in \mathbb{R}^{24w}$.

A Figura 2 ilustra uma janela de tamanho cinco amostras, com deslocamento de quatro amostras entre instantes consecutivos.

Foram avaliados sete comprimentos de janela, $w \in \{6, 12, 18, 24, 30, 36, 42\}$ ciclos, de modo a abranger diferentes escalas temporais, mantendo-se a dimensionalidade do vetor entre 84 e 504 atributos. O artigo de referência destaca o tamanho da janela como um dos principais *hiperparâmetros* do modelo; portanto, realizou-se essa busca ampla para reproduzir e validar os resultados ali reportados.

5) *Clipping do RUL.*: Adotou-se, sem nova busca de hiperparâmetros, o *piecewise linear degradation model* descrito por Ramasso [?]. Nesse esquema, o RUL é mantido constante em R_e enquanto o motor opera em condições normais; quando a diferença entre o ciclo corrente e o ciclo terminal torna-se inferior a R_e , o RUL inicia uma descida linear até zero no instante da falha. Essa limitação (“clipping”) evita que o

modelo aprenda valores irrelevantes de RUL muito altos e foca a aprendizagem na região de degradação efetiva.

Os valores de R_e utilizados correspondem exatamente aos já calibrados no artigo de referência, no caso do conjunto de dados FD001 o melhor valor de R_e encontrado foi 129. Dessa forma, garantimos comparabilidade direta com os resultados publicados, sem realizar uma nova busca exaustiva. A Figura 3 ilustra o perfil *piecewise*—RUL constante seguido de degradação linear—adotado em todo o conjunto de dados.

Para fins de entender e comprovar o impacto desta medida, foi feito o treinamento retirando a limitação para comparação.

C. Modelo — Arquitetura 1 de Laredo

Seguiu-se fielmente a descrição de [1]:

Camada	Unidades	Ativação	Informações adicionais
Totalmente Conectada	20	ReLU	$L_1 = 0.1, L_2 = 0.2$
Totalmente Conectada	20	ReLU	$L_1 = 0.1, L_2 = 0.2$
Totalmente Conectada	1	Linear	$L_1 = 0.1, L_2 = 0.2$

D. Treinamento

Hiperparâmetro	Configuração
Otimizador	Adam, $\text{lr} = 1 \times 10^{-3}$
Tamanho do lote	128
Divisão treino/validação	80 motores (treino) e 20 motores (validação)

E. Métricas de avaliação

O desempenho dos modelos foi quantificado por dois indicadores complementares. Seja N o número de amostras no conjunto de teste, y_i o RUL real do i -ésimo motor e $\hat{y}_i$ a estimativa produzida pelo modelo. Define-se $d_i = \hat{y}_i - y_i$ como o erro individual.

(i) *Erro quadrático médio global (RMSE).*: Mede a discrepância média, em unidades de ciclo, penalizando erros maiores de forma quadrática:

$$\text{RMSE} = e_{\text{rms}} = \sqrt{\frac{1}{N} \sum_{i=1}^N d_i^2}. \quad (2)$$

1) *Pontuação NASA (RUL Health Score, RHS).*: Proposta por [?], é uma função assimétrica que penaliza mais severamente predições *tardias* ($\hat{y}_i > y_i$), consideradas críticas em aplicações aeroespaciais:

$$\text{RHS} = s_{\text{rh}} = \frac{1}{N} \sum_{i=1}^N s_i \quad s_i = \begin{cases} e^{-d_i/13} - 1, & d_i < 0, \\ e^{d_i/10} - 1, & d_i \geq 0. \end{cases} \quad (3)$$

Essas métricas cobrem, respectivamente, erro médio absoluto, risco operacional de predição tardia e robustez em diferentes fases do ciclo de vida, oferecendo uma visão abrangente do desempenho do sistema.

F. Sumário dos Experimentos

Realizamos sete experimentos agrupados em quatro etapas, sempre sobre o subset FD001:

- **Etapa 1 – Baseline:** reproduzimos o pipeline original com janela de 24 ciclos e *clipping* do RUL em 129 ciclos,




Fig. 1. Sensores do motor - 1




Fig. 2. Esquema de uma janela deslizante. Fonte: Laredo *et al.* [1].




Fig. 3. Exemplo ilustrativo do *clipping* de RUL: valor constante R_e até o ciclo $t = R_e$, seguido de queda linear até zero no ciclo terminal.

a fim de confirmar que as métricas obtidas se aproximam das publicadas.

- **Etapa 2 – Sensibilidade a hiperparâmetros** : mantendo a mesma janela de 24 ciclos, vamos alterar os valores de learning-rate e de regularização e medir o impacto dessas variações.
- **Etapa 3 – Influência do *clipping***: ainda com janela de 24 ciclos, retiramos o limite de 129 ciclos para verificar como a remoção do corte afeta as previsões.
- **Etapa 4 – Comprimento da janela**: retornando aos hiperparâmetros padrão, variamos o tamanho da janela para 6, 18, 24, 30, 36, 42 e 64 ciclos, de modo a investigar o efeito de fornecer mais contexto temporal ao modelo.

O melhor experimento de cada etapa — isto é, aquele com menor `val_nasa_Score` foi então retreinado em *treino + validação* e avaliado no conjunto de teste, conforme descrito na seção seguinte.

Val rmse: 14.92 (best) | 15.05 (last)




Fig. 4. Curvas de RMSE (treino/validação) do experimento baseline — janela $w = 24$ e *clipping* $R_e = 129$.

TABLE II
COMPARATIVO RESULTADOS DO BASELINE COM O ARTIGO LAREDO *et al.* [1]

Modelo	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
Artigo	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11
Autor	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40

III. RESULTADOS E DISCUSSÃO

Nesta seção apresentamos, em quatro blocos, os resultados obtidos nas mesmas etapas descritas na Metodologia.

A. Etapa 1 – Baseline

A Fig. 4 mostra convergência estável sem sinais de *overfitting*. Os resultados comparados com o do artigo podem ser observados na tabela II. Os valores se encontram um pouco inferiores mas bastante próximos dos valores do artigo, mostrando que esse resultado foi atingido com sucesso.

No gráfico 5 podemos observar o comportamento do erro, que segue uma distribuição aproximadamente normal, centrada em $-1,8$ ciclos, indicando um leve viés de *sub-estimação* da vida útil remanescente (RUL). Cerca de 95 % dos resíduos permanecem dentro do intervalo de ± 25 ciclos, e não há caudas extremas significativas, o que confirma a robustez global do modelo.

Já os gráficos 7 e 6 mostram, respectivamente, o pior e o melhor desempenhos segmentados por *engine id*. O *Engine 85* apresenta super-estimações persistentes nos primeiros 100 ciclos, culminando em um RHS de aproximadamente 81 ciclos, enquanto o *Engine 82* demonstra aderência quase perfeita entre as curvas real e predita, com erro médio absoluto inferior a 5 ciclos. Esses casos extremos evidenciam que a variabilidade do desempenho concentra-se em poucos motores atípicos, sugerindo a necessidade de inspeção específica desses registros ou a aplicação de técnicas de re-ponderação/amostragem para mitigar seu impacto nas métricas globais.




Fig. 5. Distribuição dos erros ($e = y_{\text{true}} - y_{\text{pred}}$) no conjunto de validação.




Fig. 6. Pior desempenho do modelo base no conjunto de validação.




Fig. 7. Melhor desempenho do modelo base no conjunto de validação.

TABLE III
INFLUÊNCIA DA TAXA DE APRENDIZADO NO DESEMPENHO DE VALIDAÇÃO (FD001)

Learning rate	RMSE	RHS
0.0001	14.84	3.14
0.0010	14.54	4.17
0.0100	16.09	6.48

TABLE IV
COMPARATIVO RESULTADOS DO BASELINE COM O ARTIGO LAREDO *et al.* [1]

Modelo	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
Com Clipping	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40
Sem Clipping	25.92	28.19	26.94	0.91	47.93	154.38	94.17	43.14

TABLE V
VARIAÇÃO DO COMPRIMENTO DA JANELA

Tamanho da janela	RMSE	RHS
6	19.07	10.47
18	17.44	9.09
24	14.33	4.17
30	14.86	3.26
36	14.49	3.53
42	14.01	3.62
64	14.30	4.22

B. Etapa 2 – Sensibilidade a hiperparâmetros

Os resultados da Tabela III mostram que o learning-rate influencia modestamente o modelo: a melhor combinação ocorreu em 10^{-3} (caindo para 10^{-4} na métrica RHS), mas o ganho total de desempenho permaneceu abaixo de 4 % em relação ao valor base. Testes adicionais em que se reponderaram os termos de regularização L_1 e L_2 (não exibidos) produziram variações ainda menores, inferiores a 1% nos indicadores. Diante dessa sensibilidade muito limitada, optou-se por manter os coeficientes de regularização nos valores sugeridos no artigo de referência e concentrar a busca apenas na taxa de aprendizado.

C. Etapa 3 – Influência do clipping

A Tabela IV evidencia o papel decisivo do *clipping*. Ao remover o limite de RUL, o RMSE médio praticamente *dobrou* (de 14,75 para 26,94 ciclos), enquanto o *NASA Score* médio salta de 4,06 para 94,17—um aumento de quase 23 vezes, em linha com os achados de Laredo *et al.* [1]. Essa degradação drástica confirma que, sem o corte, a rede passa a “gastar” capacidade em valores elevados de RUL (pouco relevantes do ponto de vista operacional) e, por consequência, perde precisão justamente na faixa crítica próxima da falha. O *clipping*, portanto, não só reduz o erro global, como também orienta o modelo a emitir alertas mais confiáveis no momento correto.

TABLE VI
DESEMPENHO DO MODELO FINAL EM COMPARAÇÃO COM O *baseline*
REPRODUZIDO E O ARTIGO DE LAREDO *et al.* [1]

2*Modelo	RMSE				RHS			
	min	max	avg	std	min	max	avg	std
Artigo	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11
Baseline	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40
Proposto	14.55	15.68	14.99	0.44	3.23	5.03	3.72	0.75

D. Etapa 4 – Comprimento da janela

Os resultados indicam que o modelo necessita de um histórico mínimo de ≈ 24 ciclos: abaixo disso (6 e 18) o RMSE e o RHS disparam, sinalizando contexto insuficiente. O erro cai abruptamente entre 24 e 42 ciclos, atingindo o melhor compromisso em 30–42 ciclos (RMSE ≈ 14 –15, RHS $\approx 3,3$ –3,6). Expandir a janela para 64 ciclos não traz ganho adicional e ainda eleva ligeiramente as métricas, sugerindo sobrecarga de atributos. Assim, a faixa de 30 a 42 ciclos oferece o melhor equilíbrio entre contexto e generalização.

E. Modelo final

Após as investigações, concluiu-se que a configuração ótima não coincide integralmente com a de Laredo *et al.* [1]. Adotou-se, portanto, a combinação taxa de aprendizado $lr = 10^{-4}$, janela de 30 ciclos e *clipping* em 129 ciclos. A Fig. 8 mostra que o treinamento converge de forma suave, sem indícios de *overfitting*, mesmo após 200 épocas.




Fig. 8. Evolução da perda (RMSE) do modelo refinado.

A Tabela VI apresenta o comparativo entre o modelo proposto, o *baseline* reproduzido e os resultados do artigo de referência. Observa-se que o RMSE médio permanece na mesma ordem de grandeza (variação de $\approx 4\%$), enquanto o *NASA Score* (RHS) apresenta melhora significativa em relação ao *baseline*.

Embora os valores médios mostrem a tendência geral, eles ocultam a variabilidade entre motores. Para evidenciar essa dispersão, apresentam-se as Figs. 9 e 10.

No painel superior da Fig. 9, as curvas preditas (tracejado laranja) acompanham bem as trajetórias reais, reforçando a convergência estável mostrada na Fig. 8. O gráfico de resíduos revela que cerca de 90 % dos erros permanecem dentro do intervalo ± 20 ciclos, com **viés praticamente nulo**. Os picos positivos entre os IDs 55–65 correspondem aos mesmos motores que geram os maiores valores de RHS na Fig. 10.

A Fig. 10 confirma a redução global do RHS: aproximadamente 82 % dos motores apresentam $RHS \leq 5$, contra 70 % no *baseline*. Destaca-se, contudo, um outlier (ID 67, $RHS \approx 80$) responsável por cerca de 35 % da dispersão total da métrica. O RMSE por motor segue padrão semelhante, mas com amplitude menor, indicando que o novo treinamento efetivamente priorizou a penalização de atrasos, atendendo ao objetivo de reduzir o RHS sem comprometer o RMSE.

Além disso, observando o melhor/pior desempenho do conjunto de validação o comportamento de cada sinal é bastante próximo aos do *baseline*.

IV. CONCLUSÃO

Este trabalho reproduziu integralmente o método de Laredo *et al.* [1] para o subset FD001 e realizou uma exploração controlada de hiperparâmetros, comprovando que ajustes pontuais já são capazes de reduzir o *NASA Score* (RHS) sem penalizar o erro médio (RMSE). Os resultados principais podem ser resumidos da seguinte forma:

- **Importância do *clipping*.** Manter o limite em $R_e = 129$ ciclos mostrou-se indispensável: sua remoção quase duplicou o RMSE e fez o RHS crescer em mais de uma ordem de grandeza.
- **Sensibilidade ao *learning rate*.** A simples redução de $lr = 10^{-3}$ para 10^{-4} diminuiu o RHS em aproximadamente 9 %, com impacto negligenciável no RMSE, sugerindo que a otimização tem efeito superior a ajustes finos de regularização para este problema.

Com base nessas evidências, o **modelo final**—MLP 20–20–1 com $w = 30$, $lr = 10^{-4}$ e *clipping*—atingiu

$$RMSE_{avg} = 14,99 \quad e \quad RHS_{avg} = 3,72,$$

mantendo o RMSE no patamar do estado da arte (variação de $\approx 4\%$ em relação ao artigo) e reduzindo o RHS do *baseline* em 8,4 %. Ademais, **82 % dos motores obtiveram $RHS \leq 5$** —ante 70 % no *baseline*—, aumentando a confiabilidade para decisões de manutenção preditiva. Um único motor (ID 67) permaneceu como outlier, indicando espaço para afinamento adicional.

Contribuições principais:

- 1) Disponibilização de um *cookbook* de pré-processamento totalmente reproduzível;
- 2) Quantificação isolada dos efeitos de *clipping*, tamanho da janela e *learning rate* sobre a Arquitetura 1;
- 3) Código modular para análise detalhada de erros motor a motor.




Fig. 9. Desempenho do modelo final no conjunto de teste: painel superior — RUL real versus predito; painel inferior — resíduo por *engine id*.




Fig. 10. Variabilidade das métricas por motor no conjunto de teste: RHS (parte superior) e RMSE (parte inferior).

Perspectivas futuras:

- Avaliar o modelo nos subsets $FD00\{2-4\}$ para verificar
- robustez em múltiplos regimes operacionais;
- Investigar arquiteturas sequenciais (LSTM, GRU, CNN-

1D) ou híbridas para capturar dependências de longo alcance;

- Aplicar *sample weighting* ou *fine-tuning* dedicado a motores outliers, reduzindo o impacto de casos extremos;
- Explorar *quantile regression* ou funções de perda assimétricas, a fim de mitigar atrasos de previsão críticos.

Em síntese, demonstrou-se que um MLP compacto, aliado a escolhas criteriosas de pré-processamento e otimização, pode alcançar desempenho comparável a soluções mais complexas, oferecendo base sólida para ampliações futuras e aplicação em cenários reais de manutenção preditiva.

REFERENCES

- [1] D. Laredo, Z. Chen, O. Schütze, and J.-Q. Sun, "A neural network-evolutionary computational framework for remaining useful life estimation of mechanical systems," *Neural Networks*, vol. 116, pp. 178–187, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0893608019301224>
- [2] A. Saxena, K. Goebel, D. Simon, and N. Eklund, "Damage propagation modeling for aircraft engine run-to-failure simulation," NASA Ames Research Center, Tech. Rep. NASA/CR-2007-214490, 2007, accessed: 2025-05-28. [Online]. Available: <https://ntrs.nasa.gov/api/citations/20070034949/downloads/20070034949.pdf>
- [3] P. Malhotra, L. Vig, G. Shroff, and P. Agarwal, "Lstm-based encoder-decoder for multi-sensor anomaly detection," in *Proceedings of the 2016 International Conference on Advances in Neural Information Processing Systems*, 2016, pp. 1–8.
- [4] X. Li, Q. Ding, and J.-Q. Sun, "Remaining useful life estimation in prognostics using deep convolution neural networks," *Reliability Engineering System Safety*, vol. 172, pp. 1–11, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0951832017307779>