

Previsão de Vida Útil Remanescente de Motores Aeronauticos

1st Davi Grumiche Seemann
dept. Engenharia Elétrica
Universidade Federal de Santa Catarina
Florianópolis, SC
daviseemann@gmail.com

I. INTRODUÇÃO

A manutenção preditiva tem se tornado um pilar estratégico em indústrias intensivas em ativos, pois permite substituir o paradigma “*correção após falha*” por intervenções programadas de forma inteligente, baseadas no estado real do equipamento. Para habilitar esse cenário, é fundamental estimar com precisão a Vida Útil Remanescente (*Remaining Useful Life – RUL*) de componentes sujeitos a desgaste progressivo, como turbinas aeronáuticas, locomotivas e compressores.

A. Motivação

Meu interesse de pesquisa está em *séries temporais multivariadas*. Ao revisar a literatura, chamou-me atenção o trabalho de Laredo *et al.* [1], cuja Arquitetura 1, um MLP alimentado por janelas planificadas atingiu desempenho competitivo em problemas de RUL, desafiando a noção de que apenas redes recorrentes dominam esse domínio. Este projeto, portanto, tem como meta principal *replicar e analisar* essa arquitetura usando dados públicos, avaliando o quanto ajustes de hiperparâmetros influenciam o resultado.

B. Escolha do benchmark

O *Turbofan Engine Degradation Simulation* (C-MAPSS), disponibilizado pela NASA [2], é um benchmark de RUL muito conhecido. O conjunto oferece leituras de 24 sinais (21 sensores + 3 configurações) para motores simulados até a falha, permitindo testar modelos de prognóstico em ambiente controlado e reproduzível.

C. Objetivos deste trabalho

- 1) Construir um *pipeline* completo, de pré-processamento a avaliação, para o subconjunto FD001 do C-MAPSS.
- 2) Replicar a Arquitetura 1 de Laredo *et al.* [1] em âmbito acadêmico, avaliando a influência de hiperparâmetros e das decisões de *clipping* de RUL.

A seção seguinte revisa os trabalhos mais relevantes sobre prognóstico de turbinas e posiciona esta pesquisa no estado da arte.

D. Trabalhos Relacionados

O conjunto C-MAPSS, detalhado em [2], tornou-se o padrão de facto para validar técnicas de prognóstico de *Remaining Useful Life* (RUL) em turbinas.

TABLE I
RESULTADOS ATINGIDOS NO ARTIGO DE LAREDO *et al.* [1]

Data subset	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
FD001	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11

1) *Arquiteturas recorrentes.*: Uma linha de pesquisa dominante explora redes LSTM para capturar dependências temporais de longo prazo. Malhotra *et al.* [3] introduziram um *encoder-decoder* LSTM originalmente voltado para detecção de anomalias multissensoriais, mas rapidamente adaptado à estimativa de RUL no C-MAPSS, estabelecendo um patamar de desempenho que motivou diversas variações subsequentes.

2) *Arquiteturas densas.*: Contrariando a percepção de que somente modelos recorrentes ou Transformers seriam adequados, Laredo *et al.* [1] propuseram uma estrutura de MLP mais simples na qual a Arquitetura 1 consiste em um MLP alimentado por janelas planificadas dos sinais. Apesar da simplicidade, os autores reportaram resultados próximos aos melhores LSTM, abrindo espaço para investigações focadas em ajuste de hiperparâmetros e regularização, exatamente o escopo deste trabalho.

Em síntese, os estudos acima oferecem duas vertentes contrastantes: (a) redes recorrentes profundas com forte capacidade sequencial e (b) MLPs compactas, cuja eficácia depende de pré-processamento e tuning cuidadoso. Este projeto posiciona-se na segunda vertente, replicando e aprofundando a análise da Arquitetura 1 de Laredo *et al.* [1].

Os resultados a serem buscados especialmente no baseline são os seguintes.

II. METODOLOGIA

A. Conjunto de Dados

Utiliza-se o subconjunto FD001 do C-MAPSS [2], composto por leituras de 100 motores para treino (até a falha) e 100 para teste (trajetórias truncadas). Cada amostra contém 24 variáveis: 21 sensores físicos $S_1 - S_{21}$ e 3 configurações operacionais op_{1-3} .




Fig. 1. Esquema de uma janela deslizante. Fonte: Laredo *et al.* [1].

B. Pré-processamento

1) *Escolha dos sensores relevantes.*: A partir dos estudos de [4] e do artigo de referência [1] foram verificados que alguns sinais de sensores tinham pouco ou nenhuma correlação com a variável alvo do *dataset*. Assim este trabalho assume essa premissa como base para a escolha dos sensores a serem utilizados na parte de treino e teste do modelo. Os índices dos sensores a serem utilizados: 2, 3, 4, 7, 8, 9, 11, 12, 13, 14, 15, 17, 20, 21.

2) *Divisão entre treino e validação.*: Dos 100 motores disponíveis para treino, foi realizada a divisão por *id* de 20% dos motores para validação, ou seja, 20 motores.

3) *Normalização por motor.*: Para eliminar o viés introduzido por diferentes regimes operacionais, cada sinal foi escalonado por motor usando a normalização *min-max* no intervalo $[-1, 1]$. A Eq. (1) mostra a transformação aplicada a cada amostra $x_{i,t}$ do sensor i no ciclo t :

$$\hat{x}_{i,t} = 2 \frac{x_{i,t} - x_i^{\min}}{x_i^{\max} - x_i^{\min}} - 1, \quad (1)$$

em que $x_i^{\min} = \min_t x_{i,t}$ e $x_i^{\max} = \max_t x_{i,t}$ são, respectivamente, o mínimo e o máximo observados para o sensor i ao longo de todo o histórico daquele motor. Dessa forma, obtém-se $\hat{x}_{i,t} \in [-1, 1]$, preservando a variabilidade relativa interna de cada sensor enquanto se remove a influência das diferenças absolutas entre motores.

4) *Segmentação por janela deslizante.*: A etapa de pré-processamento adotou a estratégia de *janela deslizante* (*sliding window*) para converter as sequências de dados, de comprimento variável, em vetores de dimensão fixa adequados aos modelos de regressão. Para cada ciclo operacional t , foi construído um subconjunto $X_t \in \mathbb{R}^{w \times 24}$ contendo os w ciclos imediatamente anteriores (inclusive t); em seguida, X_t foi *planificado* linha a linha, originando o vetor de entrada $\mathbf{x}_t \in \mathbb{R}^{24w}$.

A Figura 1 ilustra uma janela de tamanho cinco amostras, com deslocamento de quatro amostras entre instantes consecutivos.




Fig. 2. Exemplo ilustrativo do *clipping* de RUL: valor constante R_e até o ciclo $t = R_e$, seguido de queda linear até zero no ciclo terminal.

Foram avaliados sete comprimentos de janela, $w \in \{6, 12, 18, 24, 30, 36, 42\}$ ciclos, de modo a abranger diferentes escalas temporais, mantendo-se a dimensionalidade do vetor entre 84 e 504 atributos. O artigo de referência destaca o tamanho da janela como um dos principais *hiperparâmetros* do modelo; portanto, realizou-se essa busca ampla para reproduzir e validar os resultados ali reportados.

5) *Clipping do RUL.*: Adotou-se, sem nova busca de hiperparâmetros, o *piecewise linear degradation model* descrito por Ramasso [?]. Nesse esquema, o RUL é mantido constante em R_e enquanto o motor opera em condições normais; quando a diferença entre o ciclo corrente e o ciclo terminal torna-se inferior a R_e , o RUL inicia uma descida linear até zero no instante da falha. Essa limitação (“clipping”) evita que o modelo aprenda valores irrelevantes de RUL muito altos e foca a aprendizagem na região de degradação efetiva.

Os valores de R_e utilizados correspondem exatamente aos já calibrados no artigo de referência, no caso do conjunto de dados FD001 o melhor valor de R_e encontrado foi 129. Dessa forma, garantimos comparabilidade direta com os resultados publicados, sem realizar uma nova busca exaustiva. A Figura 2 ilustra o perfil *piecewise*—RUL constante seguido de degradação linear—adotado em todo o conjunto de dados.

Para fins de entender e comprovar o impacto desta medida, foi feito o treinamento retirando a limitação para comparação.

C. Modelo — Arquitetura 1 de Laredo

Seguiu-se fielmente a descrição de [1]:

Camada	Unidades	Ativação	Informações adicionais
Totalmente Conectada	20	ReLU	$L_1 = 0.1, L_2 = 0.2$
Totalmente Conectada	20	ReLU	$L_1 = 0.1, L_2 = 0.2$
Totalmente Conectada	1	Linear	$L_1 = 0.1, L_2 = 0.2$

D. Treinamento

Hiperparâmetro	Configuração
Otimizador	Adam, $lr = 1 \times 10^{-3}$
Tamanho do lote	128
Divisão treino/validação	80 motores (treino) e 20 motores (validação)

E. Métricas de avaliação

O desempenho dos modelos foi quantificado por dois indicadores complementares. Seja N o número de amostras no conjunto de teste, y_i o RUL real do i -ésimo motor e $\hat{y}_i$ a estimativa produzida pelo modelo. Define-se $d_i = \hat{y}_i - y_i$ como o erro individual.

(i) *Erro quadrático médio global (RMSE)*.: Mede a discrepância média, em unidades de ciclo, penalizando erros maiores de forma quadrática:

$$RMSE = e_{rms} = \sqrt{\frac{1}{N} \sum_{i=1}^N d_i^2}. \quad (2)$$

1) *Pontuação NASA (RUL Health Score, RHS)*.: Proposta por [?], é uma função assimétrica que penaliza mais severamente predições tardias ($\hat{y}_i > y_i$), consideradas críticas em aplicações aeroespaciais:

$$RHS = s_{rh} = \frac{1}{N} \sum_{i=1}^N s_i \quad s_i = \begin{cases} e^{-d_i/13} - 1, & d_i < 0, \\ e^{d_i/10} - 1, & d_i \geq 0. \end{cases} \quad (3)$$

Essas métricas cobrem, respectivamente, erro médio absoluto, risco operacional de predição tardia e robustez em diferentes fases do ciclo de vida, oferecendo uma visão abrangente do desempenho do sistema.

F. Sumário dos Experimentos

Realizamos sete experimentos agrupados em quatro etapas, sempre sobre o subset FD001:

- **Etapa 1 – Baseline**: reproduzimos o pipeline original com janela de 24 ciclos e *clipping* do RUL em 129 ciclos, a fim de confirmar que as métricas obtidas se aproximam das publicadas.
- **Etapa 2 – Sensibilidade a hiperparâmetros**: mantendo a mesma janela de 24 ciclos, vamos alterar os valores de learning-rate e de regularização e medir o impacto dessas variações.
- **Etapa 3 – Influência do clipping**: ainda com janela de 24 ciclos, retiramos o limite de 129 ciclos para verificar como a remoção do corte afeta as previsões.
- **Etapa 4 – Comprimento da janela**: retornando aos hiperparâmetros padrão, variamos o tamanho da janela para 6, 18, 24, 30, 36, 42 e 64 ciclos, de modo a investigar o efeito de fornecer mais contexto temporal ao modelo.

O melhor experimento de cada etapa — isto é, aquele com menor `val_nasa_Score` foi então retreinado em *treino + validação* e avaliado no conjunto de teste, conforme descrito na seção seguinte.




Fig. 3. Curvas de RMSE (treino/validação) do experimento baseline — janela $w = 24$ e *clipping* $R_e = 129$.

TABLE II
COMPARATIVO RESULTADOS DO BASELINE COM O ARTIGO LAREDO *et al.* [1]

Modelo	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
Artigo	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11
Autor	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40

TABLE III
INFLUÊNCIA DA TAXA DE APRENDIZADO NO DESEMPENHO DE VALIDAÇÃO (FD001)

Learning rate	RMSE	RHS
0.0001	14.84	3.14
0.0010	14.54	4.17
0.0100	16.09	6.48

III. RESULTADOS E DISCUSSÃO

Nesta seção apresentamos, em quatro blocos, os resultados obtidos nas mesmas etapas descritas na Metodologia.

A. Etapa 1 – Baseline

A Fig. 3 mostra convergência estável sem sinais de *overfitting*. Os resultados comparados com o do artigo podem ser observados na tabela II. Os valores se encontram um pouco inferiores mas bastante próximos dos valores do artigo, mostrando que esse resultado foi atingido com sucesso.

B. Etapa 2 – Sensibilidade a hiperparâmetros

Os resultados da Tabela III mostram que o learning-rate influencia modestamente o modelo: a melhor combinação ocorreu em 10^{-3} (caindo para 10^{-4} na métrica RHS), mas o ganho total de desempenho permaneceu abaixo de 4 % em relação ao valor base. Testes adicionais em que se reponderaram os termos de regularização L_1 e L_2 (não exibidos) produziram variações ainda menores, inferiores a 1% nos

TABLE IV

COMPARATIVO RESULTADOS DO BASELINE COM O ARTIGO LAREDO *et al.* [1]

Modelo	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
Com Clipping	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40
Sem Clipping	25.92	28.19	26.94	0.91	47.93	154.38	94.17	43.14

TABLE V

VARIAÇÃO DO COMPRIMENTO DA JANELA (E5–E7)

Tamanho da janela	RMSE	RHS
6	19.07	10.47
18	17.44	9.09
24	14.33	4.17
30	14.86	3.26
36	14.49	3.53
42	14.01	3.62
64	14.30	4.22

indicadores. Diante dessa sensibilidade muito limitada, optou-se por manter os coeficientes de regularização nos valores sugeridos no artigo de referência e concentrar a busca apenas na taxa de aprendizado.

C. Etapa 3 – Influência do clipping

A Tabela IV evidencia o papel decisivo do *clipping*. Ao remover o limite de RUL, o RMSE médio praticamente *dobra* (de 14,75 para 26,94 ciclos), enquanto o *NASA Score* médio salta de 4,06 para 94,17—um aumento de quase 23 vezes, em linha com os achados de Laredo *et al.* [1]. Essa degradação drástica confirma que, sem o corte, a rede passa a “gastar” capacidade em valores elevados de RUL (pouco relevantes do ponto de vista operacional) e, por consequência, perde precisão justamente na faixa crítica próxima da falha. O *clipping*, portanto, não só reduz o erro global, como também orienta o modelo a emitir alertas mais confiáveis no momento correto.

D. Etapa 4 – Comprimento da janela

Os resultados indicam que o modelo necessita de um histórico mínimo de ≈ 24 ciclos: abaixo disso (6 e 18) o RMSE e o RHS disparam, sinalizando contexto insuficiente. O erro cai abruptamente entre 24 e 42 ciclos, atingindo o melhor compromisso em 30–42 ciclos (RMSE ≈ 14 –15, RHS $\approx 3,3$ –3,6). Expandir a janela para 64 ciclos não traz ganho adicional e ainda eleva ligeiramente as métricas, sugerindo sobrecarga de atributos. Assim, a faixa de 30 a 42 ciclos oferece o melhor equilíbrio entre contexto e generalização.

E. Modelo final

Ao término das investigações concluiu-se que a melhor configuração não necessariamente coincide integralmente com a de Laredo *et al.* [1]. Adotou-se, portanto uma nova configuração para comparação, $\mathbf{LR} = 10^{-3}$, janela de 30 ciclos e clipping em 129 ciclos. A Fig. 4 mostra que o treinamento converge sem indício de *overfitting*.




Fig. 4. Curva de treinamento modelo refinado.

TABLE VI

COMPARATIVO RESULTADOS DO MODELO FINAL, BASELINE E ARTIGO LAREDO *et al.* [1]

Modelo	RMSE				RHS			
	min	max	avg	STD	min	max	avg	STD
Artigo	14.24	14.57	14.39	0.11	3.25	3.58	3.37	0.11
baseline	14.37	15.39	14.75	0.39	3.61	4.65	4.06	0.40
final	14.51	15.55	14.92	0.43	3.05	4.82	4.64	0.69

A Tabela VI compara o desempenho do modelo proposto com o baseline reproduzido e com os valores do artigo de referência. Observa-se que o RMSE médio permanece dentro da mesma ordem de grandeza (variação de $\approx 4\%$), enquanto o *NASA Score* apresenta leve piora comparado ao baseline.

Apesar da RHS média ligeiramente mais alta, o novo conjunto de hiperparâmetros mantém o RMSE no mesmo patamar do estado-da-arte e simplifica a malha de busca. A Fig. 5 confirma que as trajetórias previstas seguem de perto o RUL real, com erros mais pronunciados apenas nos primeiros ciclos, onde o *clipping* torna-se dominante.

IV. CONCLUSÃO

Este trabalho reproduziu integralmente o modelo de Laredo *et al.* para predição de RUL no subset FD001 e, a partir dele, conduziu uma exploração focada de hiperparâmetros. Os testes mostraram que o *clipping* em 129 ciclos é indispensável para conter o erro em faixas operacionais, que janelas entre 30 e 42 ciclos oferecem o melhor equilíbrio entre contexto temporal e complexidade, e que variações moderadas no *learning-rate* influenciam o RMSE mais do que ajustes finos de regularização. O modelo final, treinado com $\mathbf{LR} = 10^{-3}$, janela = 30 e *clipping* = 129, manteve o RMSE no patamar do estado-da-arte ($\approx 14,9$) e reproduziu tendências de degradação sem sinais de *overfitting*, validando a solidez da implementação.

Os resultados confirmam que ajustes simples já proporcionam ganhos relevantes sem ampliar a malha de busca,




Fig. 5. Rul real x Rul previsto

em especial no tamanho da janela deslizando. Como trabalho futuro, recomenda-se estender a análise aos demais subsets, testar arquiteturas mais profundas (ig. LSTM ou CNN-1D). Esses passos tendem a elevar a robustez do sistema e aproximar o modelo de aplicações em campo.

REFERENCES

- [1] D. Laredo, Z. Chen, O. Schütze, and J.-Q. Sun, "A neural network-evolutionary computational framework for remaining useful life estimation of mechanical systems," *Neural Networks*, vol. 116, pp. 178–187, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0893608019301224>
- [2] A. Saxena, K. Goebel, D. Simon, and N. Eklund, "Damage propagation modeling for aircraft engine run-to-failure simulation," NASA Ames Research Center, Tech. Rep. NASA/CR-2007-214490, 2007, accessed: 2025-05-28. [Online]. Available: <https://ntrs.nasa.gov/api/citations/20070034949/downloads/20070034949.pdf>
- [3] P. Malhotra, L. Vig, G. Shroff, and P. Agarwal, "Lstm-based encoder-decoder for multi-sensor anomaly detection," in *Proceedings of the 2016 International Conference on Advances in Neural Information Processing Systems*, 2016, pp. 1–8.
- [4] X. Li, Q. Ding, and J.-Q. Sun, "Remaining useful life estimation in prognostics using deep convolution neural networks," *Reliability Engineering System Safety*, vol. 172, pp. 1–11, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0951832017307779>